



# Базовый курс от тинька

## ▼ 1 модуль: Компании и продукты

### Модели монетизации:

- рекламная модель (соц сети, поисковики)
- подписки на услуги или контент
- продажа товаров и услуг
- модель бесплатной загрузки (основной продукт бесплатный, но можно докупать доп услуги)

### Жизненный цикл продукта:

1. Разработка прототипа — анализ рынка, конкурентов. В основном этим занимается product-менеджер
2. Разработка MVP (minimal viable product) — разработка продукта, первые тесты
3. Развитие продукта — закладывается новый функционал на основе анализ данных
4. Поддержка и оптимизация — исправление ошибок тоже на основе анализа данных

## 5. \* Перестройка продукта для выхода на новые рынки

### ▼ 2 модуль: Введение в Python

Особенность Jupyter в том, что каждая строка-блок выполняется отдельно

В юпитере не нужно использовать `print()` — результат последней операции и так выводится на экран

Для вывода объемной строки, которая не вмещается в одну строчку, можно использовать тройные кавычки — `'''`

`\n` — новая строка

`\t` — табуляция

`tuple` — кортеж (англ.)

Основное отличие списка от кортежа в том, что его можно изменять (а еще кортеж записывается в круглых скобках, а список — в квадратных)

Функция не зависит от объектов и не влияет на них. А метод применим только к конкретным видам объектов и может изменять их состояние

- `abs()` — модуль числа
- `a.capitalize()` — первую буквы делает заглавной, все остальные — строчными
- `replace(a, b)` — заменяет `a` на `b` в строке
- `a.strip()` — удаляет табуляцию и конечный символ переноса в строке
- `a.lower()` — переводит все буквы в нижний регистр
- `a.center(n)` — выравнивает строку, чтоб она помещалась в колонку заданной длины
- `a.split(b)` — разбивает строку `a` по символу `b` (дефолтное значение - пробел)
- `b.join(a)` — создает общую строку из элементов `a`, разделяя их `b`

Для любой переменной `x` пишем `x.`, и юпитер выдает возможные методы и потом пояснение для выбранной функции (если не выдает — `shift + tab`)

*iterable* — объект, предоставляющий возможность поочередного прохода по своим элементам (список, строка,...)

/еще поговорили про `for` и `if`

`b = [i * 2 if type(i) == int else i for i in a]` — способ генерации списка

`import math` — импортируем библиотеку `math`, и потом юзаем в формате `math.sqrt(a)`. Или можно сразу `from math import sqrt` и юзать в формате `sqrt(a)`. А еще можно `from math import sqrt as sq` и `import pandas as pd` :)

Функция — это переменное, поэтому возможно действие формата `a = b`, где `b` — функция

*Pandas* — panel data series — библиотека для работы со статистическими данными

`import pandas as pd` — импорт пандаса

Как создать датафрейм:

- ```
df = pd.DataFrame([
    [0 for i in range(100)],
    [i for i in range(100)]
])
```

 — два списка

`df.T` — транспонирование датафрейма

- ```
df = pd.DataFrame({
    'zero': [0 for i in range(100)],
    'num': [i for i in range(100)]
})
```

 — словарь

`df['num']` — обращаемся к столбцу, причем тип полученного значения — `series`. Если хотим, чтоб получился тип `dataframe`: `df[['num']]`

Чтобы обратиться к конкретному значению датафрейма:

- `df['num'][0]`
- `df.loc[a:b:c, ['num', 'zero']]` — по сути срез датафрейма (`a/b/c` можно опустить как в обычном срезе, столбец тоже можно оставить только один). Также с

помощью этого метода можно производить замену значений внутри датафрейма

- `df.iloc[a:b:c, 1]` — в точности как `loc`, но вместо названий колонок использует их номер(a)

Несколько полезных функций:

- `df.query('num == "error"')` — возвращает дф, содержащий подходящие под условие строки (довольно медленная и простая функция)
- `df.loc[df.num == 'error', a:b:c]` — второй элемент можно полностью опустить
- `df.num.apply(lambda x: x + 1)` — изменение значений

`a = lambda x: x + 'a'` — а будет выводить итоге с соответствующей заменой, но (как я поняла) сам объект изменен не будет

- `df.num + 1` работает как предыдущий пункт, но меньше возможностей реализации

### ▼ 3 модуль: Знакомство с Excel

Рабочий файл в excel называется книгой, внутри нее — листы, состоящие из ячеек

Чтобы объединить текст из разных ячеек: `=A1&" "&A2` (в кавычках — разделение текстовых блоков)

Стрелка с ctrl — переходим на последнее числовое значение

Стрелка с shift — выделение следующей ячейки в дополнение к уже выделенным

Стрелка с ctrl и shift — выделение всего блока

Alt= — подсчет суммы по вышестоящему блоку

Формулу можно растягивать (когда появляется “+” — распространять на другие ячейки, по сути копировать. Аналогично можно растягивать последовательности или даже заставить эксель выполнять действия по аналогии (пример с фамилией)

`=ЛЕВСИМВ(A1; НАЙТИ(".".); A1)` — выводит часть текста до точки в конкретной ячейке

В экселе можно работать с массивами. Ctrl + shift + enter — работа с массивом: пример с таблицей умножения, где можно умножить столбец на ряд (а в новых версиях эксель сам понимает, что это массив, и не нужно ничего зажимать)

Главная → переносить текст, чтоб он весь поместился

Данные → текст по столбцам — можно разбить текст по столбцам (удивительно)

Фильтр и сортировка тоже находятся во вкладке "Данные"

Тыкнуть по границе столбцов двойным нажатием — он растянется до нужного размера

Ctrl + 1 — изменение формата числа

Главная → Число — можно настроить количество чисел после запятой

Ctrl + H — найти и заменить (можно, например, убрать лишние блоки текста в чилловых блоках)

В строке поиска наверху искать нужные функции

Данные → удалить дубликаты — выделение уникальных значений

=СЧЁТЕСЛИ — подсчет с условием

=СУММЕСЛИ — сумма с условием

приставка МН — несколько условий

Главная → условное форматирование — изменить форматирование (например, выделение цветов) для подходящих по условию ячеек


Данные → работа с данными → проверка данных — можно создать выпадающий список

=ВПР([Ряд]; [Таблица-источник]; [Номер столбца]) — выводит значение столбца по значению строки. Чтоб искать по 2 параметрам (типа в таблице) — в последнем значении ставим ПОИСКПОЗ

=ПОИСКПОЗ([Значение]; [Где ищем]; 0) — дает номер значения. Или же можно использовать =ИНДЕКС([Таблица]; ПОИСКПОЗ[Строка]; ПОИСКПОЗ[Столбец]) или без поиска просто подставить номера строки и столбца

\*Выделить таблицу → Вставка → Таблица → Сводная таблица — вставляется сводная таблица с оч крутым функционалом

## ▼ 4 модуль: Визуализация — теория



Визуализация пригодится в:

- анализе данных
- создании отчетов
- презентациях

Чтобы понять, какую визуализацию делать, нужно в первую очередь определиться с метриками

Виды сравнения метрик:

1. Покомпонентное (доли)
2. Позиционное (соотношение)
3. Повременное (динамика метрики во времени)
4. Частотное (количество)
5. Корреляционное (зависимость или ее отсутствие между двумя переменными)

Для сравнения категорий можно использовать линейную диаграмму, если сравнение идет по нескольким метрикам — гистограмму, а например, динамику по нескольким категориям можно показать с помощью линейного графика

Диаграмма с областями подойдет, чтоб “исправить” линейный график с слишком большим количеством метрик

Лепестковую диаграмму прикольно использовать для измерений по часам или другим циклам

Тепловая карта примеряется для метрики, изменяющейся по спирали

Винатжный анализ — линейный график созревания (изменения до какого-либо значения)

Ящик с усами (box plot) — диаграмма размаха, альтернатива — скрипичная диаграмма (violin plot)

Для большей наглядности стоит выделять важные части диаграммы и обязательно делать подписи

## ▼ 5 модуль: Визуализация — практика

Самые популярные библиотеки:

- Mathplotlib (from matplotlib import pyplot as plt)
- Seaborn (as sns)
- Plotly (import plotly.graph\_objects as go)

`df.info()` покажет основную инфу о датасете: столбцы, количество значений, тип данных. Если где-то получился object, хотя должен быть float, имеет смысл попробовать удалить NaN

Matplotlib:

- `plt.hist(df[столбец])` — строит гистограмму
- `plt.title('заголовок')`
- `plt.xlabel('подпись оси x')` и `plt.ylabel('подпись оси y')`
- `plt.grid()` — добавление сетки

Seaborn:

- `pic = sns.histplot(data=df, x='столбец', bins=кол-во столбиков, hue='второй столбец, по категории из которого будет разбивка столбиков')` — создаем гистограмму
- `pic.set(xlabel='', ylabel='', title='')` — настройка гистограммы
- `sns.countplot(y=df[''])` — линейчатая диаграмма

- `sns.countplot(df[df[''].isin(df[''].value_counts().head(3).index)][['']]` — гистограмма по трем самым частым значениям
- `sns.heatmap(table)` — тепловая карта

Plotly:

- `hist = go.Histogram(x=df[''], nbinsx=)`
- `fig = go.Figure(data=hist)`
- `fig.update_layout(
 width= размер графика
 height= высота
 title=''
 xaxis_title=''
 yaxis_title=''
)`
- `fig.show()`
- `go.Scatter(x= , y= , mode=lines)` — строим линейный график

`df.hist()` — строим гистограммы по всем числовым столбцам

## ▼ 6 модуль: Метрики

**Продукт** — ценность, которую потребитель получает при покупке товара или услуги

Продуктовый аналитик занимается продуктом: ищет проблемы, принимает решения, проводит диагностику рабочих процессов (проверяет, что все ок и сейчас, и в будущем), прогнозированием, аналитикой привлечения, исследованием поведения клиентов...

**Ориджинейшн** — путь клиента от заявки на получение продукта до его использования

**Метрика** — числовая функция, описывающая продукт

Виды метрик:

- количественные/абсолютные метрики (количество, сумма, среднее, медиана)
- относительные (доли), хороши, например, для анализа воронки продаж

Другое деление:



- пользовательские (связаны с клиентами)
- операционные (связаны с процессами и сотрудниками)

Отдельные пользовательские количественные метрики: MAU (monthly active users) — число уникальных пользователей в месяц, DAU (daily active users) — в день, WAU (weekly active users) — в неделю. И внутри этих метрик удобно смотреть соотношение новых и старых клиентов

Всегда стоит смотреть на метрики в совокупности, одна метрика не позволяет сделать корректные выводы

Базовая конверсия = успех/все. Продажная конверсия = успех/(успех+отказ).

Антифродовые метрики позволяют выявить мошенничество для искусственного улучшения метрик

Некоторые сложные метрики:

- **NPS** (net promoter score) — метрика лояльности клиента. Измеряется с помощью опросов. По вопросам типа “с какой вероятностью вы порекомендуете наш продукт?” людей делят на сторонников (обычно 9-10), нейтральных (7-8) и критиков (1-6).  $NPS = \text{Доля сторонников} - \text{доля критиков}$ . Но из-за каналов очень разнятся результаты, поэтому гораздо важнее смотреть на свою динамику, а не на значения у конкурентов
- **PnL** (profit and loss) — рассчитывается для продукта в целом. По сути прибыль, как я поняла
- **NPV** (net present value) — сколько мы заработаем с продукта. В отличие от PnL смотрим не в моменте, а как бы из будущего + все дисконтируется.  $NPV = PV$  (дисконтированные доходы, рассчитываются с помощью моделей и ML) — AC (затраты)
- **GMV** (gross merchandise value) — общая сумма денег, прошедших через сервис.  $GMV = \text{количество заказов} * \text{средний чек}$

Важно учитывать, что изменение одной метрики может привести к изменению других

Метрик смотрим либо в статике, либо в динамике. Либо в абсолюте, либо в долях.

Насчет доли тоже разные варианты:

- доля среди всех
- доля среди новых клиентов

**Сегментация** поможет для более глубокого анализа (и сегментация клиентов, и сегментация по товарам)

**Иерархия метрик** → не все метрики одинаково важны

**Когорта** — сегмент клиентов по дате начала пользования (тут еще применяется эффект дозревания → по сути как на дататоне с последним заказом)

## ▼ 7 модуль: Математическая статистика и А/Б тесты

**А/В-тест** — метод исследования, при котором сравниваются значения целевой метрики для тестовой (в которой есть изменения) и контрольной (нет изменений) групп. Пригодится, когда необходимо установить связь между переменными, проверить эффективность изменений, исключить влияние третьих факторов и получить обоснованные выводы

**Этапы проведения А/В теста:**

1. Формулировка гипотезы. Это предположение о влиянии одной переменной (независимой) на другую (зависимую)
2. Определиться с выборкой, которая поделится минимум на две группы. Аудитория должна соответствовать контексту теста + нужно учесть затраты и возможную реакцию клиентов, поэтому тестируем не на всей генеральной совокупности. Обычно используют равновероятную выборку
3. Проверка однородности групп. Нужно учесть как можно больше факторов, по которым клиенты могут отличаться (пол, возраст, регион, частота использования банка...). Лучше всего распределять рандомно
4. Подготовка к тесту и тестирование
5. Сравнение результатов и формулирование выводов, создание рекомендаций. Лучше использовать относительные значения + надо убедиться в статистической значимости. А еще надо проанализировать левые метрики, чтобы понять влияние на больших масштабах

**Случайная величина** — одно наблюдение в данных. Могут быть дискретными или непрерывными (тут тоже могут быть целые значения, просто неограниченные). У каждого случайного значения есть вероятность наступления — это **закон распределения случайной величины**

Важнейшие характеристики распределения — матожидание и дисперсия, а также мода и медиана. Нормальное распределение

**Скошенное распределение** — медиана лежит между модой и средним арифметическим

**Биномиальное распределение** — есть только 0 и 1.

Калькулятор для A/B-тестов: <https://mindbox.ru/tools/ab-test-calculator/>

Распределение поможет лучше оценить статистическую значимость. По сути статистическая значимость рассматривает, насколько разброс сопоставим с разницей средних значений в выборках

**Уровень значимости** — на сколько процентов мы уверены, что различия не случайны (никогда не может быть 100%, очев)

Разные A/B-тесты должны проводиться в разных **экспериментальных пространствах**, если же тесты находятся в одном пространстве, нужно проводить их на разных выборках. Кроме того, люди, на которых проводятся тесты в одном пространстве, должны быть равномерно распределены по группам для тестов в другом пространстве → пространства должны оставаться равномерными

Некоторые изменения нельзя протестировать из-за слишком маленького изменения, пиар и юридических рисков, отложенного эффекта

## ▼ 8 модуль: Выводы из данных

**Этапы** выводов из данных:

1. Понимание вопросов и задачи
2. Очистка и предобработка данных
3. Разведывательный анализ (EDA — exploratory data analysis) → визуализация, распределения, корреляционные матрицы... Нужно проверить, что в данных все адекватно

4. Применение статистических методов для проверки значимости
5. Выводы на основе данных + визуализация
6. Объяснение и интерпретация результатов

Корреляция не является доказательством связи

Нужно учесть, что могут быть третьи факторы

При анализе важно обойти **когнитивные искажения**, например:

- ошибка выжившего (смещенная выборка)
- отождествление корреляции и причинно-следственной связи
- необъективный анализ из-за стремления подтвердить какую-то гипотезу

Возможные факторы **искажения выводов**:

- человеческая невнимательность
- технические ошибки → важно работать с первопричиной
- сезонность
- структурные изменения
- единичные выбросы

**Юнит-экономика** — инструмент экономического анализа, позволяющий рассчитать прибыльность бизнеса за счет измерения прибыльности бизнес-юнита, т.е. одной единицы товара или одного клиента

Основные метрики юнит-экономики:

- **LTV** (lifetime value) — предсказание среднего дохода с одного пользователя
- **CAC** (customer acquisition cost) — стоимость привлечения одного клиента